

Речевой профиль спикера

Baraa Khatib Salkini

*Лингвистический анализ 8 обучающих курсов и live-стримов на
английском:
почему его речь исключительно легко воспринимается на слух*

762 323 слова · 52 583 предложения · 5 749 уникальных слов
SQL · Python · Power BI · Databricks · Data Architecture

Исследование подготовлено Demir · сентябрь 2026

Оглавление

1. Предисловие — как и почему возникло это исследование
2. Методология
3. Ключевые находки
 - 3.1. Узкий словарь как объяснение понятности
 - 3.2. Правило 80/20: 207 слов = 80% речи
 - 3.3. Закон Ципфа и формульность речи
 - 3.4. Речевой отпечаток: что общее для всех курсов
 - 3.5. Скелет построения предложения
 - 3.6. We vs I: спикер меняет личность в зависимости от формата
 - 3.7. Recorded vs live: команды против вопросов
4. Визуальная сводка
5. Коммуникационный набор (практическое ядро)
6. Генератор речи спикера
7. Приложения — полный список материалов

1. Предисловие

Я свободно читаю техническую документацию на английском — библиотеки, фреймворки, статьи по ML и Data Science не вызывают затруднений вообще. А вот с восприятием речи на слух всё было иначе: сколько бы я ни слушал разных спикеров, распознавание давалось с большим трудом.

Я решил закрыть этот пробел и начал целенаправленно тренировать listening — на знакомых темах (SQL, Python, data engineering), чтобы контекст помогал, а не мешал. Перепробовал нескольких спикеров: где-то было чуть легче, где-то так же тяжело, как и раньше.

Всё изменилось, когда я наткнулся на курсы Baraa Khatib Salkini. Я понимал его речь почти на 100% — без постоянных перемоток и повторов. Такого не было ни разу до этого.

Это не могло быть случайностью, и я решил не просто пользоваться удачным совпадением, а разобраться, что именно делает его речь настолько понятной — не на уровне ощущений «хорошая дикция», а на уровне цифр: словарь, частоты, синтаксис, построение фраз.

Так родилось это исследование — 8 транскрипций, 762 тысячи слов, и попытка препарировать речь одного конкретного человека настолько подробно, чтобы понять механику его ясности и перенять её в собственную речь.

2. Методология

Материал: транскрипты 8 курсов и стримов — SQL Full Course, Python Full Course, Power BI Data Modeling (2 курса), Databricks Live Bootcamp (Day 1 и Day 2), Data Architecture (2 live-стрима).

Метод	Что даёт
Токенизация + частотный анализ	Общий словарный запас, частота слов, словосочетаний (n-граммы 2-10 слов)
POS-разметка (spaCy)	Частота слов по частям речи по отдельности
Анализ Парето (80/20)	Минимальный набор слов, покрывающий 80% речи — по каждой части речи
Закон Ципфа	Проверка, насколько формульно распределены частоты слов
Марковские цепи (n=3)	Модель построения предложений: начала, окончания, генератор новых фраз
Межфайловое сравнение	Что общее для спикера во всех темах (речевой отпечаток), а что специфично для темы
Стилометрия (TTR, местоимения, модальность)	Сравнение live vs recorded форматов

3. Ключевые находки

3.1. Узкий словарь как объяснение понятности

Весь его словарь на 762 323 слова — 5 749 уникальных слов. Отношение уникальных слов к общему объёму текста (type-token ratio) крайне низкое — заметно ниже, чем у типичной спонтанной речи носителя языка на таком же объёме. Иными словами, он не расширяет словарь бесконечно, а сознательно (или интуитивно) работает в рамках ограниченного, повторяющегося набора конструкций.

Для человека, который воспринимает английский на слух не как носитель, это ключевой фактор: меньше незнакомых и редких слов — меньше точек, где распознавание речи срывается.

3.2. Правило 80/20: 207 слов = 80% речи

Из 5 749 уникальных слов всего 207 (3,6%) покрывают 80% всего, что он говорит. Похожая картина внутри каждой части речи: 136 из 2062 глаголов (6,6%) дают 80% всех глагольных употреблений; 303 из 3048 существительных (9,9%); 107 из 988 прилагательных (10,8%). Грамматический костяк ещё компактнее: 7 местоимений, 4 артикля, 1 сочинительный союз («and») покрывают 80% своих категорий практически полностью.

3.3. Закон Ципфа и формульность речи

Распределение частота-ранг слов в его речи ложится на почти идеальную прямую в лог-лог координатах — классическое поведение по Ципфу, без аномалий и искусственных выбросов. Это подтверждает: узость и формульность словаря — не артефакт подсчёта, а системная характеристика его речи.

3.4. Речевой отпечаток: что общее для всех курсов

76 слов входят в топ-150 абсолютно каждого из 8 файлов независимо от темы (SQL, Python, Power BI, Databricks, архитектура данных) — это подлинное ядро его личного стиля: so, we, going, now, go, like, let's, here, order, say, see... 53 биграммы и 41 триграмма демонстрируют ту же устойчивость минимум в 6 из 8 файлов. Конструкции вроде «so let's go», «as you can see», «in order to» — не случайность одного курса, а системная привычка речи.

3.5. Скелет построения предложения

Построена марковская модель (n=3) на всех 52 583 предложениях. На длинных фразах (7-10 слов) доминирует практически одна и та же растянутая конструкция — «what we're going to do, we're going to...» — сотни дословных повторений. С ростом длины фразы число уникальных вариантов резко падает: у него буквально несколько «рельсов», по которым едет почти вся речь.

3.6. We vs I: спикер меняет личность в зависимости от формата

Самая неожиданная находка. В записанных курсах местоимение «I» встречается редко (7,8-17 на 1000 слов), а «we» доминирует (37-51) — классическая инклюзивная

педагогическая позиция: «мы вместе идём по материалу». В live-стримах — почти зеркальный разворот: «I» взлетает до 37-44 (в 3-5 раз выше), а «we» падает до 12-18. В записи он ведёт группу, в live — говорит от своего лица как практик, который думает вслух.

3.7. Recorded vs live: команды против вопросов

В записанных курсах доля предложений-команд («let's create», «go and check») — 2,4-2,8%, а вопросов мало (3,3-5,1%). В live-стримах картина обратная: вопросов до 10,5% (Databricks Day 2), а команд почти вдвое меньше (0,76-1,23%). Записанный курс — сценарий «показал → сделай сам»; live — рассуждение вслух и диалог с самим собой.

4. Визуальная сводка

Облако слов (топ-150 значимых слов, весь корпус)



Рис. 1 — облако наиболее частотных содержательных слов across всех 8 курсов

Тепловая карта: частота слов по курсам




Рис. 2 — частота топ-25 слов на 1000 слов текста, в разрезе по каждому из 8 курсов. Хорошо видно всплеск «i't» именно в live-форматах (Databricks, Data Architecture)

Сеть словосочетаний

Сеть словосочетаний: топ-40 слов и их связи (биграммы)




Рис. 3 — топ-40 слов и связи между ними (биграммы). Узлы «going/we/data/order/let's» — центральные точки, вокруг которых строится вся речь

Дерево построения предложения (превью, первые уровни)




Рис. 4 — марковская цепь первых 4-7 слов предложения, топ-2/3 продолжения на развилке. Полная версия в приложении `sentence_starter_tree_deep.png`

5. Коммуникационный набор (практическое ядро)

Синтез всего исследования в формате, пригодном для ежедневной практики: словарь, начала и окончания предложений, обороты речи, переключатель We/I, шаблоны для заполнения и план отработки. Полная версия — в приложении communication_kit.md.

Грамматический каркас (выучить первым)

Категория	Слова
Местоимения (7)	we, it, you, i, 's, what, that
Вспом. глаголы (7)	is, have, can, do, are, 's, 're
Артикли (4)	the, this, a, that
Предлоги (10)	in, of, for, to, with, like, from, as, on, about
Союз (соч., 1)	and
Союзы (подч., 5)	if, that, how, because, where

Переключатель We / I

Контекст	Использовать	Почему
Обучаешь, ведёшь по шагам	WE	снижает дистанцию, «мы вместе идём по материалу»
Делишься мнением/опытом	I	звучит как эксперт, а не ведущий группы
Даёшь инструкцию	WE + повелит.	мягкая команда без давления («let's go and...»)
Рассуждаешь вслух	I + вопрос	имитация живого размышления («so what does that mean?»)

Шаблоны для заполнения

- So let's go and [verb] the [noun].
- Now what we're going to do is [verb] the [noun].
- So this is how you [verb] a [noun].
- As you can see, we have [noun] here.
- In order to [verb] the [noun], we need to [verb2].

6. Генератор речи спикера

На основе триграммной марковской модели (93 211 контекстов, топ-6 продолжений на каждый) собран рабочий генератор — `generate_speaker_sentences.py` + `trigram_model_top6.json`. Запускается локально:

```
python3 generate_speaker_sentences.py 20
```

Примеры реального вывода:

« So that means the output. »

« So now if you go with the same thing we do the data model. »

« So let's have a new data model. »

« And now if you go with the same thing we do the data model. »

Стресс-тест: 500 генераций подряд — 0 сбоев, 0 пустых результатов. Генератор пригоден для ежедневной тренировки: читать вслух сгенерированные фразы — упражнение на воспроизведение его синтаксического скелета.

7. Приложения — полный список материалов

Все файлы, созданные в ходе исследования, переданы отдельно вместе с этим отчётом.

Файл	Содержание
8 файлов *_report.md	Полный частотный анализ по каждому из 8 курсов отдельно: слова, словосочетания (n=2-10), обороты, повторяющиеся предложения
ngrams_2_10_report.md	Частотность фраз длиной от 2 до 10 слов по всему объединённому корпусу
speaker_fingerprint_report.md	Речевой отпечаток — слова/фразы, общие для всех 8 курсов независимо от темы
pos_frequency_report.md	Частота слов по каждой части речи отдельно
core_vocabulary_pareto.md	Полные списки слов 80/20 по каждой части речи с накопительным %
discourse_markers.md	32 оборота речи, сгруппированные по функции, с переводом и примерами
100_phrases.md, 100_phrases_v2.md	200 реальных речевых конструкций (без повторов) с переводом и примерами из корпуса
deep_speaker_analysis.md	Сравнение live vs recorded: местоимения, вопросы/команды, модальность, длина предложений
communication_kit.md	Итоговый практический набор: словарь + начала + обороты + окончания + шаблоны + план
anki_deck.csv	141 карточка для интервального повторения (discourse markers + словарь)
generate_speaker_sentences.py, trigram_model_top6.json	Рабочий генератор фраз в его стиле
wordcloud.png, heatmap.png, ngram_network.png	Визуализации: облако слов, тепловая карта, граф словосочетаний
sentence_starter_tree*.png, sentence_ending_tree.png	Деревья построения и завершения предложений (полное разрешение)

Практический итог исследования: понятность речи Baraa Khatib Salkini для не-носителя языка объясняется не случайностью и не «хорошей дикцией» как таковой, а измеримой структурной особенностью — узким, дисциплинированным словарём и предсказуемыми синтаксическими конструкциями, которые системно повторяются вне зависимости от темы. Материалы этого исследования переводят это наблюдение в конкретный тренировочный план.